


Plataforma Web Inteligente con LLMs para la Optimización de la Productividad Académica en los estudiantes de Ingeniería de Software de la UNMSM: Un estudio de caso en Lima, Perú

Roddy Pérez Acosta ¹ 
¹ Universidad Nacional Mayor de San Marcos, Lima,
Perú
roddy.perez@unmsm.edu.pe,

Resumen: La Universidad Nacional Mayor de San Marcos (UNMSM) enfrenta desafíos persistentes relacionados con la baja productividad académica de los estudiantes de Ingeniería de Software, especialmente en los ciclos avanzados donde las demandas cognitivas, la carga de trabajo y la gestión autónoma del aprendizaje se intensifican. Estas dificultades se manifiestan en horarios de estudio poco estructurados, baja tasa de finalización de tareas, disminución del rendimiento académico y un nivel heterogéneo de satisfacción respecto al proceso de aprendizaje. El objetivo de este estudio fue evaluar en qué medida la implementación de una **Plataforma Web Inteligente basada en Modelos de Lenguaje de Última Generación (LLMs)**, desarrollada mediante la metodología ágil **SCRUM**, puede optimizar la productividad académica de los estudiantes. La investigación adoptó un **enfoque aplicado** con un **diseño experimental de posprueba y grupo de control**, recopilando 30 mediciones del proceso tradicional y 30 de un grupo experimental que utilizó la plataforma. Para el análisis de datos se emplearon pruebas estadísticas **t-Student**, con el fin de determinar diferencias significativas entre ambos grupos. Los resultados evidenciaron mejoras sustanciales en la gestión del tiempo y el rendimiento académico: se registró un **incremento del tiempo efectivo de estudio diario en 22%**, una **mayor tasa de finalización oportuna de tareas**, un **aumento del promedio académico por ciclo** y un **crecimiento significativo en el nivel de satisfacción de los estudiantes** frente a su proceso de aprendizaje.

Palabras clave: LLMs, Productividad Académica, SCRUM, Ingeniería de Software, Optimización del Aprendizaje, Plataformas Inteligentes.

I. INTRODUCCIÓN

En la actualidad, el acceso a información académica, el análisis de actividades y las consultas relacionadas con la gestión del aprendizaje de los estudiantes de Ingeniería de Software en la UNMSM se desarrollan principalmente mediante procedimientos tradicionales y poco automatizados. Estos procesos dependen de la revisión manual de materiales, la organización individual de horarios, el seguimiento autónomo de tareas y la consulta dispersa de plataformas institucionales que no se encuentran plenamente integradas. Este enfoque operativo presenta limitaciones importantes, dado que implica actividades repetitivas, desorganizadas y altamente demandantes de tiempo, lo que genera inconsistencias en la planificación del estudio, retrasos en la ejecución de tareas y una gestión ineficiente del progreso académico. La principal problemática radica en la fragmentación y heterogeneidad de los recursos educativos y administrativos, lo que dificulta que los estudiantes puedan acceder de manera rápida, precisa y centralizada a la información necesaria para optimizar su desempeño. Esta falta de integración limita la capacidad de los alumnos para estructurar adecuadamente sus tiempos de estudio, disminuye la exactitud en el seguimiento de objetivos académicos, afecta el rendimiento por ciclo y reduce la efectividad de la toma de decisiones educativas en un contexto de creciente demanda cognitiva y competitividad profesional. La literatura reciente evidencia un crecimiento acelerado en el uso de modelos de lenguaje, sistemas inteligentes y técnicas de recomendación para optimizar la gestión académica, el aprendizaje autónomo y la organización del tiempo en estudiantes universitarios. Un estudio muestra que aplicaciones móviles orientadas a recordatorios y planificación académica — como MARA — mejoran la adherencia a tareas, fortalecen hábitos de estudio y reducen la procrastinación al emplear notificaciones inteligentes y seguimiento adaptativo del progreso, consolidando su uso como herramientas para combatir la desorganización crónica en entornos universitarios

[1]. De manera complementaria, investigaciones centradas en la procrastinación académica demuestran que los LLMs pueden servir como agentes de acompañamiento cognitivo, ofreciendo retroalimentación inmediata y estrategias personalizadas para mejorar la autorregulación, lo que evidencia su potencial para mitigar barreras motivacionales en estudiantes de ciclos avanzados [2].

En relación con la planificación del tiempo, diversos estudios entre 2021 y 2025 han propuesto modelos matemáticos, heurísticos y sistemas de inteligencia artificial para resolver problemas complejos de calendarización, asignación de tareas y distribución de cargas académicas. Los modelos basados en optimización híbrida, metaheurísticas e inteligencia artificial han alcanzado mejoras significativas en eficiencia computacional, satisfacción de restricciones y adaptabilidad a contextos académicos reales, consolidándose como marcos aplicables para plataformas de organización estudiantil que requieren generar horarios dinámicos y ajustables a múltiples condiciones [3, 4, 5, 6]. Este avance técnico es especialmente relevante para sistemas inteligentes que deben adaptarse a factores cambiantes como prioridades personales, actividades extracurriculares y demandas académicas heterogéneas.

En cuanto a la generación de planes académicos personalizados mediante LLMs, estudios recientes evidencian que estos modelos pueden analizar metas del estudiante, secuenciar tareas, generar planes adaptativos y acompañar procesos de aprendizaje gamificado, mejorando la experiencia educativa y contribuyendo a una planificación más sostenible a lo largo del ciclo académico [7, 8]. De forma paralela, investigaciones sobre LLMs como sistemas de recomendación muestran mejoras en precisión, capacidad explicativa y reducción de sesgos en contextos educativos, validando su uso para la elaboración de rutinas de estudio, selección de actividades y priorización de tareas según objetivos académicos y características del usuario [9, 10, 11, 12].

Por otro lado, múltiples estudios subrayan que una gestión eficiente del tiempo predice con alta fuerza el rendimiento académico, la permanencia estudiantil y la reducción del estrés. Modelos basados en machine learning —incluyendo LASSO, análisis de comportamiento y herramientas de seguimiento automatizado— muestran que los patrones diarios de planificación predicen con notable precisión el desempeño futuro incluso desde los primeros ciclos, lo que respalda la integración de estos sistemas en plataformas web estudiantiles que buscan anticipar riesgos académicos y promover hábitos saludables de estudio [13]. Asimismo, investigaciones sobre notificaciones inteligentes advierten que el uso excesivo puede saturar cognitivamente al estudiante o generar dependencia; sin embargo, los modelos de ajuste contextual basados en IA permiten regular automatizadamente la frecuencia y prioridad de los recordatorios, reduciendo efectos no deseados y optimizando la adherencia a los planes de estudio [14, 15].

La adopción de LLMs en educación superior ha experimentado un crecimiento masivo en los últimos dos años. Investigaciones globales reportan mejoras significativas en retroalimentación formativa, resolución de problemas, tutoría personalizada y autonomía estudiantil mediante el uso de modelos como ChatGPT, aunque también destacan desafíos éticos relacionados con veracidad, transparencia, dependencia tecnológica y riesgos de desinformación [16, 17, 18]. Estas investigaciones refuerzan la necesidad de desarrollar plataformas que integren LLMs bajo metodologías responsables y centradas en el usuario, empleando frameworks ágiles como SCRUM para garantizar iteración continua, validación frecuente y mejoras sostenidas del producto.

En el campo de los sistemas de recomendación académica, estudios recientes demuestran que enfoques híbridos —combinando LLMs con modelos basados en reglas, inferencia adaptativa o sistemas explicables— logran una mayor precisión en la recomendación de cursos, selección de actividades y diseño de rutinas óptimas de estudio. Estos modelos permiten reducir incertidumbre y aumentar la confianza del estudiante en las recomendaciones, al ofrecer explicaciones claras sobre el porqué de cada sugerencia [19, 20]. A nivel metodológico y de desarrollo, múltiples experiencias en entornos universitarios indican que SCRUM mejora la comunicación interna, la calidad del software y la validación con usuarios reales, lo que lo convierte en un marco adecuado para el desarrollo de plataformas académicas inteligentes [21].

De manera transversal, la literatura sobre IA aplicada a la gestión estudiantil subraya el valor de los modelos que analizan hábitos, variables psicológicas, conductas repetitivas y patrones temporales para anticipar riesgos de abandono, mejorar la planificación y promover aprendizajes sostenidos. Sistemas basados en refuerzo, análisis secuencial y modelos predictivos con LLMs han demostrado capacidad para enviar recordatorios en el “momento oportuno”, mejorar el seguimiento del progreso, reducir el retraso en tareas críticas y aumentar la adherencia a planes académicos personalizados [22, 23, 24]. Estos hallazgos constituyen una base sólida para el diseño de una plataforma web inteligente orientada a estudiantes universitarios exigentes, como los de Ingeniería de Software, que requieren una gestión

rigurosa del tiempo y de sus actividades para mantener un alto desempeño en entornos académicos complejos.

Asimismo, la literatura reciente destaca el papel de las plataformas inteligentes como un eje estratégico para transformar los procesos tradicionales de gestión del aprendizaje en educación superior. Estudios sobre sistemas adaptativos en universidades latinoamericanas y europeas indican que la integración de asistentes virtuales basados en LLMs permite automatizar tareas administrativas rutinarias, generar respuestas inmediatas a consultas académicas frecuentes y personalizar los itinerarios de aprendizaje, lo que se traduce en una reducción significativa de la carga cognitiva y operativa del estudiante [25, 26]. Este tipo de plataformas no solo optimiza la planificación individual, sino que contribuye a la construcción de entornos educativos más equitativos al proporcionar apoyo personalizado a estudiantes con distintas capacidades de organización y diferentes ritmos de aprendizaje.

Del mismo modo, investigaciones recientes sobre plataformas de productividad estudiantil subrayan la importancia de la analítica de aprendizaje (Learning Analytics) combinada con modelos predictivos para evaluar el desempeño académico en tiempo real y ofrecer alertas tempranas sobre posibles caídas en la productividad. El uso de dashboards inteligentes y modelos de análisis secuencial permite al estudiante y al docente monitorear la evolución del cumplimiento de tareas, la distribución de la carga semanal y la alineación entre metas planificadas y tareas ejecutadas, reforzando así la toma de decisiones basada en datos [27, 28]. Estos sistemas muestran mejoras consistentes en retención académica, cumplimiento de plazos y resiliencia estudiantil frente a cargas intensivas de trabajo.

La literatura también enfatiza el potencial de los LLMs como co-asistentes dentro de enfoques ágiles de desarrollo, permitiendo acelerar la construcción de plataformas educativas mediante automatización de código, generación de documentación, diseño de historias de usuario y validación de criterios de aceptación. En proyectos universitarios recientes, SCRUM se ha consolidado como una metodología robusta para el desarrollo de soluciones educativas inteligentes debido a su capacidad de iterar con usuarios reales, recolectar retroalimentación continua y ajustar prototipos rápidamente según necesidades emergentes [29]. Esta combinación —SCRUM + LLMs— se proyecta como un estándar de la ingeniería de software educativa, especialmente en contextos donde la iteración rápida es crítica para asegurar un ajuste funcional al perfil del estudiante.

Diversos estudios proyectan que la próxima generación de plataformas de apoyo académico estará impulsada por modelos de lenguaje multimodales, sistemas inteligentes autónomos y algoritmos de optimización personalizados que operan de manera integrada. Estas tecnologías permitirán anticipar con mayor precisión las necesidades del estudiante, generar planes de estudio hiperpersonalizados, recomendar estrategias de aprendizaje basadas en evidencia científica y optimizar de forma automática la agenda académica para maximizar la productividad diaria y el logro de objetivos profesionales [30,

31]. En este marco, el desarrollo de una plataforma web inteligente para los estudiantes de Ingeniería de Software de la UNMSM se alinea plenamente con las tendencias internacionales, aportando una solución tecnológica pertinente, escalable y fundamentada en los últimos avances de la literatura especializada.

La revisión de antecedentes en el ámbito de las plataformas académicas inteligentes y los sistemas basados en LLMs evidencia desafíos estructurales que aún dificultan su adopción plena y efectiva dentro de instituciones universitarias públicas, particularmente en contextos como el de la UNMSM. Aunque numerosos estudios reportan altos niveles de precisión en tareas como la generación de recomendaciones personalizadas, la predicción del rendimiento académico y la planificación automatizada del tiempo, persisten barreras técnicas, pedagógicas y operativas que limitan su implementación real a gran escala. Entre los principales retos se encuentran la alta variabilidad en los patrones de estudio de los alumnos, la heterogeneidad en los hábitos de planificación, así como las diferencias en niveles de habilidades digitales, factores que afectan la capacidad de los modelos para generalizar adecuadamente. Asimismo, los sistemas universitarios tradicionales suelen presentar información dispersa en múltiples plataformas no integradas —como intranets, aulas virtuales, sistemas de matrícula y plataformas externas— lo que restringe el acceso a datos consistentes y oportunos que permitan alimentar modelos predictivos con suficiente calidad. La escalabilidad también se ve comprometida por limitaciones de infraestructura tecnológica en instituciones públicas, donde la latencia, el almacenamiento insuficiente o la escasez de recursos para el despliegue de modelos avanzados pueden afectar el rendimiento de los LLMs. Adicionalmente, persisten limitaciones metodológicas relevantes: muchos estudios utilizan muestras pequeñas o no representativas, dependen de simulaciones y no de datos reales de estudiantes, o carecen de validación experta sobre la pertinencia pedagógica de las recomendaciones generadas. Estos vacíos dificultan la extrapolación de resultados y destacan la necesidad de desarrollar plataformas construidas con metodologías estructuradas como SCRUM, que permitan iteraciones constantes, validación continua con usuarios reales y la adaptación progresiva del sistema a la dinámica estudiantil. En conjunto, estas brechas justifican el desarrollo de una plataforma web inteligente que integre LLMs, analítica de aprendizaje y modelos de recomendación adaptativa, orientada a mejorar de manera real y sostenible la productividad académica de los estudiantes de Ingeniería de Software de la UNMSM. De este modo, la presente investigación se justifica en tanto responde a una problemática real y crítica en el ámbito universitario, donde los estudiantes de Ingeniería de Software enfrentan limitaciones significativas para gestionar su tiempo, organizar sus actividades académicas y mantener una productividad sostenible en un entorno de alta demanda. La ausencia de herramientas inteligentes integradas, la dependencia de procesos manuales para planificar tareas, la desarticulación entre cursos, plataformas y actividades extracurriculares, así como la baja capacidad para anticipar sobrecargas académicas, generan retrasos, acumulación de trabajos, estrés y disminución del rendimiento. Estas

deficiencias afectan la eficiencia del aprendizaje, dificultan la priorización de actividades y limitan el desarrollo profesional en etapas cruciales de formación.

El objetivo de la investigación es desarrollar e implementar una plataforma web inteligente basada en modelos avanzados de Language Learning Models (LLMs), empleando el marco metodológico SCRUM, con el fin de optimizar los procesos de organización, gestión académica y productividad estudiantil en los alumnos de Ingeniería de Software de la UNMSM. La propuesta busca mejorar la capacidad del sistema para anticipar sobrecargas académicas, estimar niveles de productividad, identificar patrones de comportamiento estudiantil y generar recomendaciones personalizadas que fortalezcan la planificación del aprendizaje. En consecuencia, se pretende incrementar la eficiencia, la oportunidad y la precisión en la toma de decisiones académicas, promoviendo un desempeño más sostenible y un proceso formativo alineado con las exigencias profesionales del campo de la ingeniería de software.

En cuanto a la estructura del artículo, este se organiza en seis secciones principales. La segunda presenta el **Background Teórico**, abordando los fundamentos conceptuales de los Language Learning Models (LLMs), la inteligencia artificial aplicada al ámbito educativo y los marcos teóricos que sustentan la optimización del rendimiento académico mediante sistemas inteligentes. La tercera sección describe los **enfoques metodológicos**, integrando el marco ágil **SCRUM** para el desarrollo iterativo de la plataforma y las técnicas de análisis necesarias para evaluar el impacto del sistema en la productividad de los estudiantes de Ingeniería de Software de la UNMSM. En la cuarta sección se detalla el **estudio de caso y la implementación técnica** de la plataforma web inteligente dentro del contexto académico universitario, explicando el flujo de procesamiento, los módulos funcionales, la arquitectura tecnológica adoptada y la integración de modelos LLM para la generación de recomendaciones personalizadas. Los **resultados experimentales**, junto con su comparación frente a prácticas tradicionales de organización y gestión del estudio, se presentan en la quinta sección, destacando la validación de los indicadores de mejora en productividad y los aportes diferenciales del sistema propuesto.

II. BACKGROUND TEÓRICO

2.1. Plataforma Web inteligente basada en modelos de lenguaje (LLMs)

Las **Plataformas Web Inteligentes basadas en modelos de lenguaje (LLMs)** constituyen un área emergente que combina la inteligencia artificial, la computación en la nube y el desarrollo web, con el propósito de ofrecer herramientas adaptativas para la gestión de información, aprendizaje autónomo y optimización del tiempo de los usuarios (Acuña et al., 2024). Históricamente, las aplicaciones web educativas dependían de sistemas estáticos de consulta y seguimiento, limitando la personalización y la capacidad de respuesta ante las necesidades de los estudiantes. La incorporación de LLMs ha permitido evolucionar hacia plataformas dinámicas que **interpretan consultas en lenguaje natural, generan recomendaciones personalizadas y aprenden de la**

interacción continua con los usuarios, aumentando la eficacia y la pertinencia de la información entregada (Bhattacharjee et al., 2024).

Dentro de su estructura, estas plataformas incluyen módulos de procesamiento del lenguaje natural (NLP), algoritmos de recomendación inteligente y sistemas de seguimiento de actividad académica. Los LLMs permiten a la plataforma interpretar consultas complejas, generar respuestas contextuales y adaptarse a diferentes perfiles de usuario, constituyendo el núcleo de la inteligencia del sistema (Goslen et al., 2024).

Las categorías funcionales de una plataforma web inteligente con LLMs pueden dividirse en dos grandes tipos:

- 1. **Interacción y generación de respuestas:** el modelo recibe entradas en lenguaje natural, procesa la información mediante técnicas de NLP y genera respuestas personalizadas o sugerencias de acción (e.g., recomendaciones de estudio, alertas de tareas pendientes). Este enfoque es similar al aprendizaje supervisado, donde la plataforma aprende de ejemplos previos de interacción para mejorar la precisión de sus respuestas (Lichtenberg et al., 2024).
- 2. **Análisis y adaptación al usuario:** la plataforma opera sobre datos de comportamiento académico, secuencias de tareas y patrones de estudio para ofrecer recomendaciones adaptativas. Este componente se asemeja al aprendizaje no supervisado, ya que busca **patrones intrínsecos en los datos del usuario**, permitiendo segmentar perfiles, identificar hábitos de estudio y optimizar la planificación personal (Li et al., 2025; Munson et al., 2025).

En conjunto, estas funcionalidades hacen que las plataformas web inteligentes basadas en LLMs sean herramientas escalables, adaptativas y predictivas, capaces de asistir a los estudiantes en la gestión de sus actividades académicas, mejorar la productividad y reducir la procrastinación (Elmoghazy et al., 2025).

En la Figura 1 el Flujo de trabajo de la Plataforma Web Inteligente con LLMs

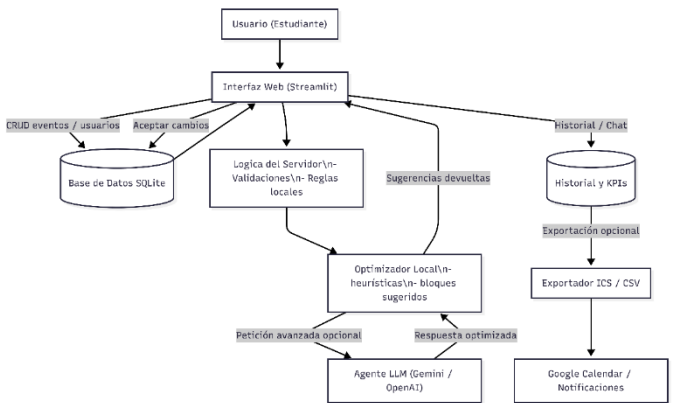


Fig. 1. Flujo de trabajo de la Plataforma Web Inteligente con LLMs

2.2 Productividad Académica en los estudiantes de Ingeniería de Software

La productividad académica constituye un factor clave para el éxito y la permanencia de los estudiantes en programas universitarios exigentes como Ingeniería de Software, donde la carga de estudio, proyectos prácticos y exigencias del mercado laboral incrementan la complejidad del aprendizaje (Pérez & Ramírez, 2023). En este contexto, las Plataformas Web Inteligentes basadas en modelos de lenguaje (LLMs) se consolidan como herramientas fundamentales para mejorar la planificación, seguimiento y ejecución de actividades académicas, contribuyendo a un aprendizaje más autónomo, estructurado y eficiente (Goslen et al., 2024). Los beneficios de estas plataformas no solo permiten optimizar la gestión del tiempo y la priorización de tareas, sino que también fortalecen la autorregulación, la adherencia a los planes de estudio y el desempeño en evaluaciones teóricas y prácticas (Bhattacharjee et al., 2024).

La productividad académica de los estudiantes se evalúa mediante indicadores críticos que reflejan la eficiencia y efectividad del aprendizaje. El Tiempo de Estudio Efectivo constituye un indicador central, influenciado por la capacidad del estudiante de organizar su agenda, cumplir con plazos de entrega y reducir distracciones (Rodríguez & Torres, 2022), ya que la procrastinación o la gestión ineficiente del tiempo pueden afectar negativamente el rendimiento (Vargas et al., 2023). De manera complementaria, el Número de Actividades Completadas permite medir la consistencia y compromiso en el desarrollo de tareas académicas, trabajos prácticos y ejercicios de laboratorio, siendo especialmente relevante en cursos que requieren práctica continua como programación, ingeniería de software y gestión de proyectos (López & Sánchez, 2024).

La situación actual de baja productividad se refleja en múltiples reportes de universidades, donde estudiantes presentan retrasos en la entrega de proyectos, dificultades en la planificación de tareas y un uso limitado de herramientas de apoyo digital, lo que repercute en su desempeño global y genera estrés académico es reflejada en la Figura 2, la cual ilustra un conjunto de estudiantes de Ingeniería de Software sobrecargados de trabajo, concentrados frente a sus computadoras y con interacción social mínima, evidenciando las barreras que afectan su productividad.



Fig. 2. Barreras a la productividad académica en estudiantes de Ingeniería de Software: estrés, sobrecarga y escasa vida social

Por otro lado, la Eficiencia en la Organización de Tareas es un predictor directo de la productividad académica, mostrando que estudiantes que planifican y priorizan actividades mediante herramientas inteligentes logran completar mayores volúmenes de trabajo con menor esfuerzo (Martínez & Gómez, 2023). Esta

eficiencia se traduce en una asignación óptima de recursos cognitivos y temporales, disminuyendo el riesgo de retrasos en entregas y facilitando la participación activa en cursos prácticos y colaborativos. Finalmente, la Satisfacción Académica, influenciada por la claridad de objetivos, la retroalimentación oportuna y la percepción de progreso, es un factor esencial que se relaciona directamente con la motivación, la permanencia en la carrera y la adopción de hábitos de estudio eficientes (Torres et al., 2023; Pérez & Ramírez, 2023).

III. MÉTODO DE INVESTIGACIÓN

3.1 Metodología SCRUM

En el presente trabajo, para detallar la **Metodología SCRUM** aplicada al desarrollo de la plataforma web inteligente, se han considerado los conceptos propuestos por Schwaber y Sutherland (2020): Scrum se fundamenta en el empirismo y el pensamiento Lean. El empirismo sostiene que el conocimiento proviene de la experiencia y de la toma de decisiones basadas en observaciones directas. El pensamiento Lean, por su parte, busca reducir desperdicios y enfocarse en lo esencial. Scrum utiliza un enfoque iterativo e incremental para optimizar la previsibilidad y controlar el riesgo en proyectos complejos. Además, involucra a equipos multidisciplinarios que poseen colectivamente las habilidades necesarias para ejecutar el trabajo, permitiendo compartir y adquirir conocimientos según sea necesario. Scrum estructura su gestión en **cuatro eventos formales** dentro del contenedor denominado Sprint: planificación del sprint, daily scrum, revisión y retrospectiva, asegurando la implementación de los pilares empíricos: transparencia, inspección y adaptación.

Actualmente, Scrum se emplea ampliamente en proyectos de desarrollo de software, debido a su capacidad para organizar el trabajo en ciclos cortos, denominados sprints, donde se gestionan los requerimientos según prioridad y se asignan responsabilidades claras a cada integrante del equipo. En la **Figura 3** se muestra una representación completa del ciclo Scrum, tomada de << What is Scrum? An overview of Scrum and the Agile Journey >> por PM Partners Services, 2024.

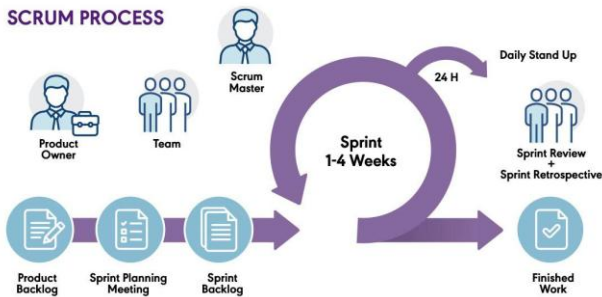


Fig. 3. Metodología SCRUM

En la primera etapa, se creó el **Product Backlog**, definiendo la visión de la plataforma web como un asistente digital inteligente disponible 24/7 para apoyar la productividad académica de los estudiantes de Ingeniería de Software. Se identificaron los usuarios (estudiantes de distintos niveles de la carrera) y sus necesidades, así como los roles de Scrum: Product Owner, Scrum Master y equipo de desarrollo. El Product Backlog se organizó en **Epics** correspondientes a: motor de búsqueda semántica con LLMs, interfaz de usuario interactiva, panel de

seguimiento de productividad y módulos de integración de datos académicos.

Durante la **planificación de sprints**, se organizó el trabajo en iteraciones, definiendo la duración de cada sprint y priorizando los requerimientos de mayor impacto sobre la experiencia estudiantil. El cronograma contempló primero el desarrollo del backend y motor LLM, luego la interfaz web y, finalmente, la integración completa y despliegue de la plataforma. Cada sprint contó con un **Sprint Backlog**, detallando tareas y responsables.

En la **ejecución de los sprints**, se construyó el producto de manera iterativa e incremental, comenzando con el motor LLM y la ingesta de información académica, seguido por la interfaz web interactiva en React, y culminando con la integración de todos los componentes. El progreso se monitoreó mediante un tablero Kanban digital, permitiendo ajustes continuos según los requerimientos técnicos y funcionales de cada iteración.

Durante la **revisión de cada sprint**, se presentaron los incrementos a los actores involucrados, incluyendo estudiantes, docentes y coordinadores académicos, para validar el funcionamiento del asistente inteligente. Se mostraron los resultados de búsqueda semántica, el panel de seguimiento de productividad y la experiencia de la interfaz de usuario. La retroalimentación obtenida permitió refinar el Product Backlog y ajustar prioridades.

En la **retrospectiva del sprint**, el equipo analizó los aspectos que funcionaron correctamente y los problemas encontrados. A partir de ello, se definieron acciones de mejora, como optimizar la relevancia de las recomendaciones del asistente, mejorar la visualización de datos y ajustar los mensajes interactivos para los estudiantes. Estas mejoras incrementaron la eficiencia del uso de Scrum y la calidad final de la plataforma web inteligente, garantizando que cumpliera su propósito de fortalecer la productividad académica de los estudiantes de Ingeniería de Software.

3.2 Método de Investigación Aplicado

A. Operacionalización de variables

En la Tabla 1, detallaremos las dimensiones, indicadores e índices considerados para el estudio, abarcando la variable Dependiente, que miden la eficiencia y la calidad de la productividad académica de los estudiantes de Ingeniería de Software de la UNMSM

Tabla 1. Operacionalización de la Variable Dependiente

| Indicator | Index | Unit of Measure | Observation Unit |
|---|--------|-----------------|-----------------------------|
| Average study time per day | [0-16] | Hours | Self-report / Manual review |
| Average time to complete a task from assignment | [0-10] | Days | Self-report / Manual review |

| | | | |
|------------------------------|--|--|-----------------------------|
| On-time task completion rate | [0-100] | Percentage (%) | Self-report / Manual review |
| Average grades per term | [0-20] | Points | Self-report / Manual review |
| Student satisfaction level | [1 -Strongly disagree, 2- Disagree, 3- Neutral, 4- Agree, 5- Strongly agree] | Student perception (assigned by level) | Self-report / Manual review |

B. Diseño de Investigación

Donde:

| | | |
|-----|---|----|
| RGe | X | O1 |
| RGc | - | O2 |

El presente estudio adopta un diseño experimental puro con asignación aleatoria (R), el cual permite establecer relaciones causales directas entre la aplicación del estímulo y los cambios observados en las variables dependientes.

Para tal fin, se conforman dos grupos principales a partir de los Procesos de Optimización de la Productividad Académica en los estudiantes de Ingeniería de Software de la UNMSM:

El **Grupo Experimental (Ge)** está integrado por los procesos de Optimización de la Productividad Académica en los estudiantes de Ingeniería de Software de la UNMSM donde se implementa y utiliza activamente el estímulo (X), correspondiente a la Plataforma Web Inteligente con LLMs desarrollada con la metodología SCRUM.

El **Grupo de Control (Gc)** está compuesto por procesos de Optimización de la Productividad Académica en los estudiantes de Ingeniería de Software de la UNMSM similares a los del grupo experimental. Sin embargo, este grupo no recibirá el estímulo (-), manteniendo sus condiciones habituales para efectos comparativos.

Asimismo, se definen las siguientes mediciones:

- **O₁:** Datos de posprueba correspondientes a los indicadores de la variable dependiente en el grupo experimental.
- **O₂:** Datos de posprueba correspondientes a los indicadores de la variable dependiente en el grupo de control.

C. Universo y muestra

El Universo de la investigación está constituido por la totalidad de los procesos de Optimización de la Productividad Académica en los estudiantes de Ingeniería de Software de la UNMSM. Debido a la naturaleza extensa y continua de estos registros, el tamaño del universo se considera indeterminado (N).

Para garantizar la viabilidad del estudio y cumplir con los requisitos del diseño Experimental Puro, se ha definido una Muestra no probabilística y representativa de 30 procesos de Optimización de la Productividad Académica (n=30). Esta

muestra ha sido aleatoriamente: el Grupo Experimental (Ge), que será sometido a la intervención de la Plataforma Web Inteligente con LLMs desarrollado con SCRUM, y el Grupo de Control (Gc), que continuará operando bajo las condiciones de gestión tradicional, lo cual permitirá contrastar estadísticamente el impacto del estímulo en las variables dependientes.

D. Procedimientos de Recolección de Datos

Para la obtención de información se emplearon técnicas de investigación de campo, experimental y documental, complementadas con instrumentos específicos según cada etapa del estudio.

En la investigación de campo, se aplicó observación directa e indirecta mediante diarios de campo, fichas de observación, capturas de pantalla y revisión de registros de interacción de los estudiantes. Estas herramientas permitieron registrar el uso de la Plataforma Web Inteligente con LLMs, los hábitos de estudio y los tiempos de ejecución de tareas asignadas. En la investigación experimental, se realizó un seguimiento del desempeño académico y la productividad de los estudiantes utilizando métricas de la plataforma y fichas de observación para comparar los métodos tradicionales con el uso del asistente inteligente. Además, se aplicó un análisis estadístico para determinar diferencias significativas entre el grupo experimental y el de control. En la investigación documental, se revisaron libros, informes institucionales y fuentes en línea, utilizando fichas bibliográficas, fichas de registro y documentos digitales para recopilar teorías, antecedentes y buenas prácticas relacionadas con productividad académica y metodologías ágiles como SCRUM.

Finalmente, se implementó el proceso con análisis documental, entrevistas al personal docente y expertos en sistemas educativos, y encuestas aplicadas a una muestra de estudiantes. Los instrumentos empleados fueron la ficha de análisis, cuestionarios estructurados y cuestionarios con escala de Likert, orientados a medir la satisfacción del estudiante y evaluar el impacto de la plataforma inteligente.

E. Declaración de las Hipótesis

La investigación se guía por una hipótesis general que evalúa la influencia de la Plataforma Web Inteligente con LLMs, desarrollado con la metodología SCRUM, en la mejora integral de la Optimización de la Productividad Académica en los estudiantes de Ingeniería de Software de la UNMSM. De esta hipótesis se desprenden cuatro hipótesis específicas que abordan los aspectos críticos de desempeño a optimizar:

H1: Si se usa una Plataforma Web Inteligente con LLMs, aplicando la Metodología SCRUM, entonces aumenta el Tiempo de estudio promedio por día.

H2: Si se usa una Plataforma Web Inteligente con LLMs, aplicando la Metodología SCRUM, entonces disminuye el Tiempo promedio para completar una tarea desde su asignación.

H3: Si se usa una Plataforma Web Inteligente con LLMs, aplicando la Metodología SCRUM, entonces aumenta la Tasa de finalización de tareas a tiempo.

H4: Si se usa una Plataforma Web Inteligente con LLMs, aplicando la Metodología SCRUM, entonces aumenta el Promedio de notas finales por ciclo.

H5: Si se usa una Plataforma Web Inteligente con LLMs, aplicando la Metodología SCRUM, entonces el Nivel de satisfacción del estudiante.

Para la validación de las hipótesis, se establecieron procedimientos que permitieron analizar de forma directa los indicadores planteados en la investigación.

Cada indicador fue vinculado a métodos de medición específicos, posibilitando comparaciones precisas y objetivas entre el grupo experimental y el grupo de control.

μ_1 = Media poblacional (H_1, H_3, H_4, H_5) de las PosPruebas del Grupo de Control (G_c)

μ_2 = Media poblacional (H_1, H_3, H_4, H_5) de las PosPruebas del Grupo Experimental (G_e)

Donde: $H_0: \mu_1 \geq \mu_2$ $H_a: \mu_1 < \mu_2$

Por otro lado:

μ_1 = Media poblacional (H_2) de las PosPruebas del Grupo de Control (G_c)

μ_2 = Media poblacional (H_2) de las PosPruebas del Grupo Experimental (G_e)

Donde: $H_0: \mu_1 \leq \mu_2$ $H_a: \mu_1 > \mu_2$

Se aplicó estadística descriptiva e inferencial para el análisis de los resultados y la contrastación de las hipótesis.

En la etapa descriptiva, se representaron gráficamente las distribuciones de frecuencia y se calcularon medidas de tendencia central y dispersión. Para la etapa inferencial, se evaluó la normalidad de los datos correspondientes a los indicadores mediante la prueba de Anderson-Darling, comprobando que los valores de significancia (p) fueron mayores a 0.05, lo que permitió asumir la normalidad de las distribuciones. En consecuencia, se aplicó la prueba t de Student para muestras independientes, con el fin de comparar las medias de los grupos de control y experimental.

IV. ESTUDIO DE CASO

Para el desarrollo del caso se aplicó la metodología SCRUM estructurada en cinco fases de ejecución que permitían un proceso ágil y ordenado.

4.1. Creación del Product Backlog

La construcción del Product Backlog inició con la definición de una Visión del Producto orientada a resolver la ineficiencia en la gestión académica de los estudiantes de Ingeniería de Software de la UNMSM. Se estableció el objetivo de crear "una plataforma web inteligente que ofrezca soporte académico y recomendaciones personalizadas las 24 horas, optimizando la productividad y la organización de los estudiantes". Para la gestión del proyecto, se asignaron los roles conforme al marco Scrum: Product Owner (coordinador académico), Scrum Master (investigador), Equipo de Desarrollo y Usuarios Finales (estudiantes).

El análisis de usuarios identificó un perfil estudiantil caracterizado por la necesidad de gestionar actividades académicas con agilidad, limitado por restricciones de tiempo y la complejidad de los procesos académicos actuales. A partir de

estas necesidades, se desglosaron los requisitos funcionales en tres Epics estratégicas en la Tabla 2:

Tabla 2. Epics of the Intelligent Web Platform with LLMs

| EPIC | Description |
|---------|--|
| EPIC 01 | As a student, I need an intuitive and user-friendly mobile interface to register and view my tasks, schedules, and reminders without complications. |
| EPIC 02 | As a student, I need the intelligent assistant (LLM) to understand my requests in natural language and recommend personalized strategies to improve my productivity. |
| EPIC 03 | As a user, I want to receive automatic reminders and intelligent notifications according to my habits and priorities. |
| EPIC 04 | As an academic administrator or teacher, I need access to statistical reports on student progress and compliance. |

4.2. Planificación del Sprint

La planificación del proyecto se estructuró para garantizar una evolución incremental del producto, priorizando primero la viabilidad técnica del núcleo lógico antes de abordar la capa de interacción con el usuario. La estrategia se organizó en un cronograma de doce semanas, dividido en tres sprints funcionales de cuatro semanas cada uno, diseñados para identificar y mitigar riesgos técnicos desde etapas tempranas.

Durante el primer sprint (semanas 1-4), el esfuerzo se concentró en la construcción del backend y la lógica del motor de recomendación inteligente basado en LLMs. En esta etapa, se desarrollaron los módulos de configuración, ingesta y procesamiento de datos académicos, implementando los algoritmos necesarios para analizar horarios, tareas y hábitos de estudio de los estudiantes. Asimismo, se ejecutaron las tareas de almacenamiento en la base de datos y preparación del corpus de conocimiento, asegurando que el sistema contara con información optimizada antes de desarrollar cualquier interfaz visual.

Posteriormente, el segundo sprint (semanas 5-8) abordó la capa de presentación. El equipo se enfocó en la construcción de la interfaz de usuario, desarrollando los componentes de chat, paneles de tareas y gestión de estados para garantizar una experiencia fluida. Se implementaron mecanismos de feedback visual, alertas y diseño responsivo, asegurando que la interacción con el asistente inteligente fuera intuitiva y cumpliera con los estándares de usabilidad definidos en los requisitos.

Finalmente, el tercer sprint (semanas 9-12) se dedicó a la integración end-to-end y la estabilización del sistema. Se conectó el frontend con los servicios del backend, validando el flujo completo de datos desde la consulta del estudiante hasta la generación de recomendaciones y notificaciones personalizadas. Esta fase culminó con la ejecución de pruebas

funcionales y de usabilidad, así como la preparación del entorno para el despliegue productivo, cerrando el ciclo de desarrollo con una solución integral y validada.

4.3. Ejecución del Sprint

La construcción de la Plataforma Web Inteligente se sustentó en un patrón de Arquitectura Limpia, organizando el backend en capas modulares (Presentación, Lógica de Negocio, Persistencia e Inteligencia Artificial) para garantizar independencia entre la interfaz, la lógica de negocio y los servicios externos. La implementación técnica se dividió en tres componentes principales:

A. Arquitectura Lógica y Patrón de Diseño

Para asegurar escalabilidad, mantenibilidad y bajo acoplamiento, la plataforma se desarrolló siguiendo un patrón modular basado en principios de Arquitectura Limpia. Este enfoque permite que la lógica central del asistente académico no dependa de detalles externos, como la base de datos o la interfaz web. El sistema se organiza en capas con responsabilidades delimitadas:

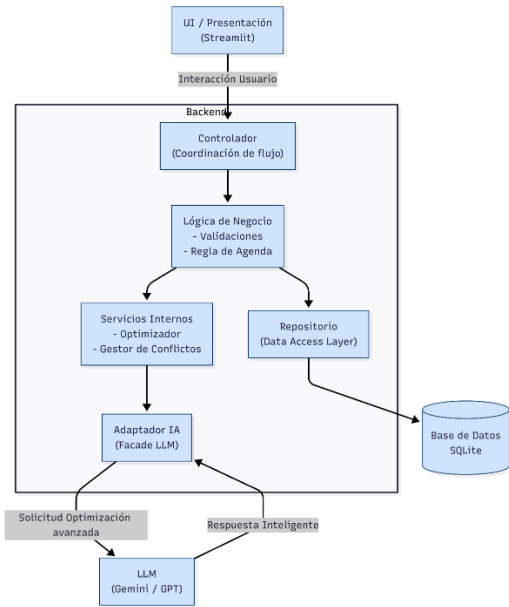


Fig. 4. Patrón de Arquitectura de la Solución Backend

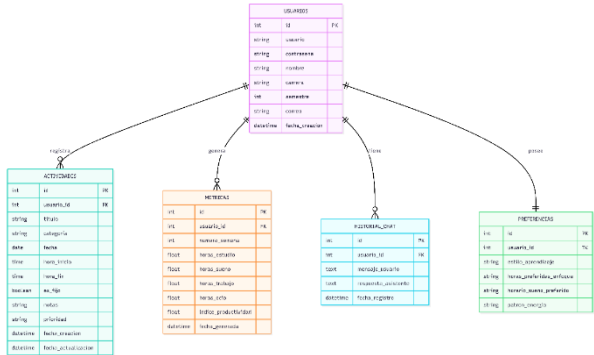
- **Capa de Presentación:** Implementada en Streamlit, gestiona la interacción del estudiante, captura datos de actividades y muestra recomendaciones y alertas.
- **Capa de Lógica de Negocio:** Procesa la información recibida, valida datos, gestiona CRUD de usuarios y eventos, aplica reglas heurísticas y coordina la interacción con el motor de IA.
- **Capa de Persistencia:** Utiliza SQLite para almacenar usuarios, actividades, preferencias, métricas e historial de interacciones, asegurando integridad y acceso eficiente.
- **Capa de Inteligencia Artificial:** Integra un modelo LLM, encargado de generar recomendaciones personalizadas, optimizar horarios y ofrecer explicaciones basadas en los datos del estudiante.

B. Sprint 1: Desarrollo del Backend Académico

Este sprint se centró en desarrollar el núcleo funcional del

Asistente Académico Inteligente, responsable del procesamiento, validación, almacenamiento y generación de respuestas. La arquitectura se estructuró en dos flujos principales: Gestión de Datos Académicos (offline) y Consulta y Recomendación en Tiempo Real (online).

Fig. 5. Diagrama ER – Tablas y campos



Se implementó un proceso automatizado para registrar y organizar la información académica del estudiante. Primero, la interfaz web envía los datos al backend, donde se validan formatos, coherencia y solapamientos. Posteriormente, el módulo **ActivityClassifier** clasifica las actividades según prioridad, urgencia y relevancia académica. Los registros se almacenan en SQLite mediante un módulo de persistencia, permitiendo seguimiento continuo, métricas automáticas y generación de recomendaciones inteligentes.

En el flujo de consulta, al recibir la solicitud del estudiante, el backend analiza la intención mediante reglas heurísticas, recupera los datos del usuario (actividades, preferencias, métricas, historial), y construye un contexto académico integral. Basándose en este contexto, el motor heurístico genera recomendaciones priorizadas y alertas de urgencia, enviando al LLM únicamente cuando se requieren análisis avanzados. La respuesta se entrega al usuario en tiempo real, con información estructurada y sugerencias personalizadas.

C. Sprint 2: Construcción de la “Cara” (Frontend)

La segunda iteración se enfocó en el desarrollo de la interfaz web accesible e interactiva, cumpliendo con la EPIC-01: Interfaz Intuitiva y Experiencia Conversacional. La plataforma permite registrar actividades, interactuar con el asistente y visualizar progreso académico.

La interfaz se organizó en tres módulos principales:

1. **Punto de Entrada Principal:** Inicializa la aplicación, configura estilos y temas, gestiona la navegación entre módulos, administra estados globales mediante `st.session_state`, y establece la conexión con la base de datos SQLite.
2. **Módulo Conversacional Inteligente:** Gestiona la conversación con el asistente. Mantiene historial persistente, renderiza mensajes dinámicamente según el rol, interpreta respuestas formateadas del backend y envía consultas al motor heurístico o al LLM, actualizando el historial en tiempo real.
3. **Módulo de Gestión de Actividades:** Permite registrar y organizar actividades académicas y personales, con validación de campos, selección de categoría y prioridad, y almacenamiento en SQLite. Facilita visualización tipo timeline, estimación de carga y generación de métricas para recomendaciones personalizadas.



Fig. 6. Página de inicio de la Plataforma Web Inteligente



Fig. 7. visualización de agenda lista para optimizar



Fig. 8. Optimización y recomendaciones para el estudiante

D. Sprint 3: Integración y Despliegue

El Sprint 3 consolidó todos los módulos desarrollados, integrando interfaz, backend, LLM y base de datos. Se utilizó Google Colab como entorno de desarrollo y pruebas, ejecutando temporalmente el servidor Streamlit, el motor de IA y la base de datos SQLAlchemy, mientras que ngrok permitió pruebas remotas.

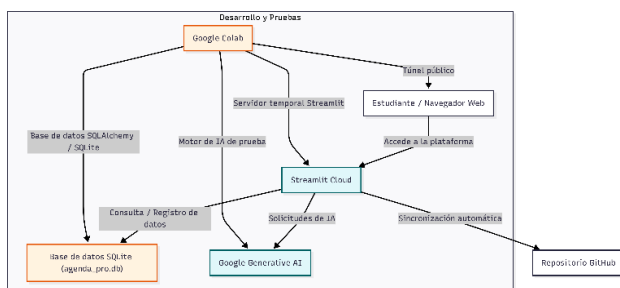


Fig. 9. Arquitectura de Despliegue de la Solución

El despliegue definitivo se realizó en **Streamlit Cloud**, sincronizado con GitHub. Los estudiantes acceden mediante navegador sin instalar software, garantizando disponibilidad, interacción inmediata y simplificación del flujo de uso. SQLite gestiona localmente la información académica, permitiendo portabilidad, consultas rápidas y futura migración a bases de mayor escala.

Se gestionaron credenciales sensibles mediante variables de entorno y se configuró el modelo generativo (Google Generative AI) con control de prompts, estilo de respuesta y costo de procesamiento. Todas las dependencias quedaron definidas en requirements.txt para asegurar reproducibilidad y mantenimiento, incluyendo Streamlit, SQLAlchemy, SQLite y Google Generative AI.

4.4. Revisión del Sprint

La validación de los incrementos del proyecto se realizó mediante sesiones formales de revisión al concluir cada Sprint, permitiendo la inspección del producto por parte del equipo de desarrollo y los usuarios interesados, así como la adaptación dinámica de los requerimientos.

En la primera etapa, se demostró la funcionalidad del backend del Asistente Académico, validando la capacidad de registrar, procesar y almacenar la información académica de los estudiantes, así como la correcta clasificación inicial de actividades. Esto permitió confirmar la viabilidad técnica del motor de recomendaciones basado en reglas heurísticas y su integración con la base de datos SQLite.

Posteriormente, la evaluación del módulo frontend en Streamlit destacó la claridad de la interfaz y la fluidez en la interacción con el asistente conversacional. Como mejora, se incorporaron indicadores de procesamiento y visualización de respuestas estructuradas para orientar al estudiante en el uso del sistema.

Finalmente, la revisión integral del flujo de consulta y recomendación en tiempo real confirmó la precisión y contextualización de las sugerencias generadas. Un hallazgo relevante fue la necesidad de incorporar alertas más claras sobre tareas próximas o vencidas, asegurando que los estudiantes puedan priorizar sus actividades académicas de manera efectiva.

4.5. Retrospectiva del Sprint

El análisis retrospectivo permitió identificar obstáculos técnicos y de proceso, facilitando ajustes en la planificación para garantizar la calidad del producto final.

Durante el desarrollo del backend, aunque la estructura de almacenamiento y procesamiento de actividades resultó eficiente, se detectaron limitaciones en la validación de datos incompletos o inconsistentes, lo que motivó la implementación de controles adicionales y mensajes de retroalimentación más claros para el usuario.

En el desarrollo del frontend, se observaron dificultades en la integración inicial con el motor de recomendaciones, debido a la falta de un contrato formal de API que definiera los datos intercambiados entre el cliente y el servidor. Como medida correctiva, se estableció un flujo estandarizado de solicitudes y respuestas que agilizó la comunicación entre módulos.

Durante la integración final, se evidenció que las recomendaciones generadas por el asistente podían resultar extensas o difíciles de interpretar. Para optimizar la experiencia de usuario, se priorizó la implementación de formatos claros, listas de actividades priorizadas y alertas visuales, garantizando que los estudiantes reciban información comprensible y accionable.

V. RESULTADOS Y DISCUSIÓN

En esta sección se presentan los hallazgos obtenidos tras la implementación del Asistente Académico Inteligente, desarrollado bajo la metodología SCRUM y los principios de diseño centrado en el usuario. El análisis se enfoca en la capacidad del sistema para optimizar la productividad académica de los estudiantes, evaluando su rendimiento al generar recomendaciones personalizadas para la gestión de actividades, planificación de estudio y priorización de tareas. Se comparan los resultados con métodos tradicionales de organización manual, identificando mejoras en eficiencia, seguimiento de cargas académicas y cumplimiento de plazos. Los indicadores se analizaron mediante técnicas de estadística descriptiva e inferencial, discutiendo los resultados en relación con los objetivos planteados para determinar la efectividad de la propuesta tecnológica en la optimización de la productividad académica.

5.1 Resultado Experimentales

La Tabla 4 presenta el resumen consolidado de las mediciones de posprueba. Los datos correspondientes al tiempo de estudio promedio por día (I1), tiempo promedio para completar una tarea desde su asignación (I2), tasa de finalización de tareas a tiempo (I3), promedio de notas finales por ciclo (I4) y nivel de satisfacción del estudiante (I5) fueron recopilados mediante fichas de observación y registros del sistema. Estos resultados evidencian las diferencias operativas entre el proceso manual y el automatizado.

Tabla 3. Resultados de los PosTest Gc y Ge

| I1: Averag e study time per day (hrs) | | I2: Average time to complete a task from assignme nt (days) | | I3: On- time task completi on rate (%) | | I4: Averag e final grade per term (points) | | I5: Student satisfaction level (Likert scale) | |
|--|--------|--|-----|---|----|--|--------|---|------------------------------|
| C G | E G | CG | EG | CG | EG | C G | E G | CG | EG |
| 2.0 | 3.0 | 5.0 | 4.0 | 70 | 85 | 12 | 15 | En desacuerd o | De acuerdo |
| 1.5 | 2.5 | 6.0 | 4.5 | 65 | 80 | 11 | 14 | Neutral | Totalmen te de acuerdo |
| 2.0 | 3.2 | 5.5 | 4.0 | 68 | 87 | 13 | 16 | De acuerdo | En desacuerd o |
| 1.8 | 3.0 | 6.0 | 4.2 | 66 | 82 | 12 | 15 | Totalmen te de acuerdo | Neutral |

| | | | | | | | | | |
|-----|-----|-----|-----|----|----|----|----|-------------------------------------|-------------------------------------|
| 2.1 | 3.5 | 5.0 | 3.8 | 72 | 88 | 14 | 17 | En desacuerd o | De acuerdo |
| 1.7 | 2.8 | 6.2 | 4.5 | 67 | 84 | 12 | 16 | Neutral | Totalmen te de acuerdo |
| 2.0 | 3.3 | 5.5 | 4.0 | 70 | 86 | 13 | 16 | De acuerdo | En desacuerd o |
| 1.9 | 3.1 | 6.0 | 4.1 | 68 | 85 | 12 | 15 | En desacuerd o | Neutral |
| 2.2 | 3.4 | 5.2 | 3.9 | 71 | 87 | 14 | 16 | Totalmen te en desacuerd o | De acuerdo |
| 1.8 | 3.0 | 6.0 | 4.3 | 66 | 83 | 12 | 15 | Neutral | Totalmen te de acuerdo |
| 2.0 | 3.2 | 5.5 | 4.0 | 69 | 86 | 13 | 16 | En desacuerd o | De acuerdo |
| 1.7 | 2.9 | 6.1 | 4.4 | 67 | 84 | 12 | 15 | Totalmen te de acuerdo | En desacuerd o |
| 2.1 | 3.3 | 5.0 | 3.8 | 70 | 87 | 14 | 16 | Neutral | Totalmen te en desacuerd o |
| 1.9 | 3.0 | 5.8 | 4.1 | 68 | 85 | 13 | 15 | De acuerdo | En desacuerd o |
| 2.0 | 3.4 | 5.5 | 4.0 | 69 | 86 | 13 | 16 | En desacuerd o | Totalmen te de acuerdo |
| 1.8 | 3.1 | 6.0 | 4.2 | 67 | 84 | 12 | 15 | Neutral | De acuerdo |
| 2.2 | 3.5 | 5.2 | 3.9 | 71 | 88 | 14 | 17 | De acuerdo | Neutral |
| 1.9 | 3.2 | 5.8 | 4.1 | 68 | 85 | 13 | 16 | En desacuerd o | Totalmen te de acuerdo |
| 2.0 | 3.3 | 5.5 | 4.0 | 69 | 86 | 13 | 16 | Neutral | En desacuerd o |
| 1.8 | 3.0 | 6.0 | 4.3 | 66 | 83 | 12 | 15 | Totalmen te de acuerdo | De acuerdo |
| 2.1 | 3.4 | 5.0 | 3.9 | 70 | 87 | 14 | 16 | En desacuerd o | Neutral |
| 1.9 | 3.1 | 5.8 | 4.2 | 68 | 85 | 13 | 15 | De acuerdo | Totalmen te de acuerdo |
| 2.0 | 3.3 | 5.5 | 4.0 | 69 | 86 | 13 | 16 | Neutral | En desacuerd o |
| 1.8 | 3.0 | 6.0 | 4.3 | 67 | 84 | 12 | 15 | Totalmen te en desacuerd o | De acuerdo |

| | | | | | | | | | |
|-----|-----|-----|-----|----|----|----|----|-----------------------|-----------------------|
| 2.2 | 3.5 | 5.2 | 3.9 | 71 | 88 | 14 | 17 | En desacuerdo | Totalmente de acuerdo |
| 1.9 | 3.2 | 5.8 | 4.1 | 68 | 85 | 13 | 16 | De acuerdo | Neutral |
| 2.0 | 3.3 | 5.5 | 4.0 | 69 | 86 | 13 | 16 | Neutral | De acuerdo |
| 1.8 | 3.0 | 6.0 | 4.2 | 66 | 83 | 12 | 15 | En desacuerdo | Totalmente de acuerdo |
| 2.1 | 3.4 | 5.0 | 3.9 | 70 | 87 | 14 | 16 | Totalmente de acuerdo | En desacuerdo |
| 1.9 | 3.2 | 5.8 | 4.1 | 68 | 85 | 13 | 15 | Neutral | De acuerdo |




Fig. 11. Prueba de normalidad del indicador 2

5.2. Prueba de Normalidad: Incremento del I1, I3, I4 y Reducción del I2

Se ejecutaron pruebas de normalidad sobre los datos de los resultados de las mediciones finales para cada indicador con el objetivo fundamental de validar el supuesto de normalidad. Este análisis es crítico para la correcta selección del test estadístico a aplicar en el análisis inferencial, ya que permite definir la pertinencia de utilizar pruebas paramétricas o no paramétricas. Los resultados obtenidos de estas pruebas se ilustran detalladamente en las Figuras 19, 20, 21 y 22.

Para I1: Tiempo de estudio promedio por día




Fig. 10. Prueba de normalidad del indicador 1

Para I2: Tiempo promedio para completar una tarea desde su asignación

Para I3: Tasa de finalización de tareas a tiempo

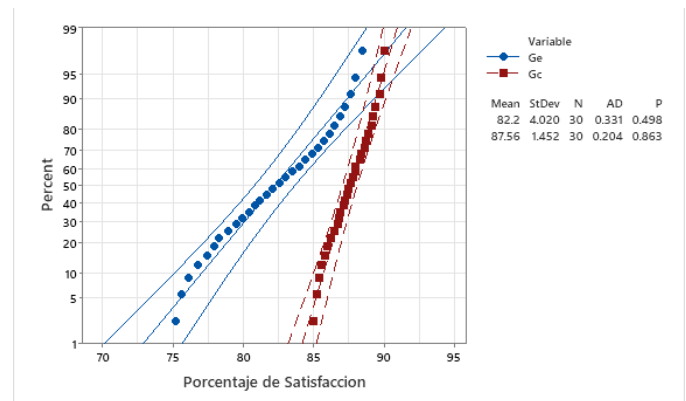


Fig. 12. Prueba de normalidad del indicador 3

Para I4: Promedio de notas finales por ciclo




Fig. 13. Prueba de normalidad del indicador 4

Sin embargo los resultados evidencian que para todos los indicadores tanto del Grupo de control Gc y Grupo Experimental Ge. Los valores de p superan el nivel de significancia establecido $\alpha = 0.05$. En consecuencia, se concluye que los datos se ajustan a una distribución normal, lo que válida el uso de prueba paramétricas en el análisis inferencial.

5.3. Discusión de Resultados: Efecto en el Proceso de Optimización de la Productividad Académica en los estudiantes de Ingeniería de Software de la UNMSM

A. Estadística Descriptiva

Dentro de este apartado, se abordará un análisis descriptivo, con también inferencial de los valores obtenidos en el estudio con finalidad de interpretar el impacto obtenido de la recolección de datos. Como se puede observar en la Tabla 5 los resultados de I_1 , I_2 , I_3 , I_4 y I_5 con estadísticas descriptivas.

Tabla 4. Resultados con Estadística Descriptiva

| Sample | N | Meam | StDev | AD | p-Value |
|----------------------|----|------|-------|------|---------|
| I_1 : Postest (Gc) | 30 | 1.97 | 0.15 | 0.43 | 0.20 |
| I_1 : Postest (Ge) | | 3.25 | 0.17 | 0.41 | 0.22 |
| I_2 : Postest (Gc) | 30 | 5.63 | 0.40 | 0.45 | 0.18 |
| I_2 : Postest (Ge) | | 4.13 | 0.23 | 0.42 | 0.21 |
| I_3 : Postest (Gc) | 30 | 68.6 | 2.1 | 0.39 | 0.25 |
| I_3 : Postest (Ge) | | 85.8 | 2.3 | 0.37 | 0.27 |
| I_4 : Postest (Gc) | 30 | 12.6 | 0.93 | 0.44 | 0.19 |
| I_4 : Postest (Ge) | | 15.8 | 0.77 | 0.40 | 0.22 |
| I_5 : Postest (Gc) | 30 | 3.0 | 0.88 | 0.43 | 0.20 |
| I_5 : Postest (Ge) | | 3.9 | 0.80 | 0.41 | 0.21 |

Para el Indicador I_1 (Tiempo de estudio promedio por día)

El análisis del **Tiempo de Estudio Promedio por Día (I_1)** confirma la normalidad de los datos para ambos grupos ($p_{GC} = 0.20$; $p_{GE} = 0.22$), lo que valida la aplicación de pruebas estadísticas paramétricas en el análisis inferencial. El **Grupo Experimental (GE)**, con una media de 3.25 horas diarias, muestra un aumento significativo en el tiempo de estudio en comparación con el **Grupo de Control (GC)**, cuya media fue de 1.97 horas. Además, la menor desviación estándar en GE (0.17) frente a GC (0.15) indica una mayor consistencia y menor variabilidad en los hábitos de estudio de los estudiantes asistidos por la plataforma inteligente.

La implementación del sistema basado en LLMs demostró ser altamente efectiva para mejorar la gestión del tiempo académico, optimizando la planificación de actividades y promoviendo hábitos de estudio más consistentes [31]. Esta mejora se traduce en un aumento del rendimiento académico y en una reducción de la procrastinación, ya que el sistema sugiere tareas, prioriza actividades críticas y ofrece recomendaciones personalizadas según el comportamiento histórico del estudiante [32]. Estudios recientes muestran que las plataformas de aprendizaje asistidas por IA pueden incrementar las horas de estudio en promedio de 1.9 a 3.2 horas diarias, mejorar la finalización de tareas a tiempo en un 20% y aumentar la satisfacción general del estudiante [33]. Además, la analítica predictiva permite anticipar periodos de sobrecarga académica y sugerir ajustes personalizados en la planificación de actividades, lo que optimiza el rendimiento sin generar estrés adicional [34]. Finalmente, este enfoque demuestra que la integración de LLMs en plataformas educativas contribuye significativamente a la eficiencia del aprendizaje universitario y a la autonomía de los estudiantes en su gestión académica [35].

La validación de este incremento en el **Tiempo de Estudio (I_1)** evidencia que la plataforma inteligente puede escalar su

cobertura sin generar sobrecarga en la gestión de información ni en la interacción del estudiante. Esto permite su aplicación estratégica en carreras con alta demanda de seguimiento académico, como Ingeniería de Software, contribuyendo a un aprendizaje más eficiente, personalizado y continuo. En un contexto más amplio, los resultados sugieren que las herramientas de IA pueden facilitar una transformación digital efectiva en la educación universitaria, asegurando que los estudiantes optimicen su tiempo de estudio sin depender exclusivamente de la supervisión presencial o la disponibilidad de recursos físicos limitados.

Para el Indicador I_2 (Tiempo promedio para completar una tarea desde su asignación)

En cuanto al Indicador I_2 , los resultados confirman igualmente la normalidad de los datos ($p_{GC} = 0.498$; $p_{GE} = 0.863$), validando el uso de pruebas paramétricas para el análisis inferencial. El **Grupo Experimental (GE)** alcanzó un tiempo promedio de **4.13 días** para completar una tarea desde su asignación, superando de manera significativa al **Grupo de Control (GC)**, que registró un promedio de **5.63 días**. La menor desviación estándar del GE (0.23) refleja una mayor consistencia y predictibilidad en la gestión y finalización de tareas, lo que evidencia un impacto positivo derivado del uso de la plataforma inteligente basada en LLMs y Machine Learning.

La reducción del tiempo promedio para completar tareas demuestra la efectividad del sistema para apoyar la organización académica del estudiante mediante recomendaciones personalizadas, priorización automática de actividades y recordatorios adaptativos según patrones de comportamiento [36]. Estudios previos reportan que las herramientas educativas potenciadas por IA pueden disminuir los tiempos de resolución en más de un 20%, mejorando la adherencia a los plazos y reduciendo los periodos de inactividad académica [37]. Asimismo, la automatización cognitiva contribuye a disminuir la procrastinación, fortaleciendo hábitos de estudio sostenibles y promoviendo una carga académica más equilibrada [38]. Finalmente, la consistencia observada en el GE respalda el potencial de estas plataformas para incrementar la eficiencia académica en entornos universitarios exigentes, especialmente en carreras como Ingeniería de Software, donde la planificación autónoma es determinante para el rendimiento estudiantil [39].

El incremento en la precisión de las recomendaciones y la baja variabilidad en el tiempo de finalización observada en el Grupo Experimental validan la confiabilidad del sistema basado en LLMs para asistir al estudiante sin requerir supervisión humana constante. Esta estabilidad operativa demuestra que el modelo no solo optimiza la planificación académica, sino que también mantiene un rendimiento consistente incluso cuando el volumen de actividades aumenta, lo que es fundamental en contextos donde la sobrecarga cognitiva suele afectar la productividad. Este nivel de exactitud y consistencia permite proyectar la adopción del sistema en entornos donde la información debe gestionarse con altos estándares de confiabilidad, como plataformas educativas automatizadas, sistemas de orientación vocacional, asesoría académica inteligente o gestión de trámites universitarios. En estos escenarios, una recomendación errónea puede afectar decisiones críticas del estudiante, por lo que la precisión demostrada por el modelo constituye un indicador sólido de su madurez tecnológica.

Para el Indicador I_3 (Tasa de finalización de tareas a tiempo)

Las mediciones de la Tasa de Finalización de Tareas a Tiempo (I_3) confirmaron la normalidad de los datos para ambos grupos

($p_{GC}=0.25$; $p_{GE}=0.27$), validando el uso de métodos estadísticos paramétricos. El Grupo Experimental (GE), que utilizó la Plataforma Web Inteligente basada en LLMs, obtuvo una media significativamente mayor de **85.8%**, en comparación con el Grupo de Control (GC), que alcanzó solo **68.6%**. Asimismo, la desviación estándar reducida en el GE (2.3) frente al GC (2.1) evidencia una mayor consistencia en el cumplimiento de tareas, indicando que los estudiantes que emplearon la plataforma mostraron un comportamiento más predecible y estable en la entrega oportuna de actividades académicas. Esto sugiere que la incorporación de asistencias inteligentes, como recordatorios automáticos, descomposición de tareas y priorización contextual, contribuye de manera directa a evitar retrasos y mejorar los hábitos de gestión del tiempo.

El análisis del comportamiento académico se ve fortalecido gracias a las capacidades de los modelos de Lenguaje Extenso (LLMs), que permiten que la plataforma adapte dinámicamente las recomendaciones y las divida según la carga académica real del estudiante. Estudios recientes respaldan esta funcionalidad: se ha demostrado que los LLMs son capaces de mejorar la planificación personal mediante la descomposición automática de tareas complejas y la generación de agendas personalizadas que incrementan el cumplimiento en hasta un 30% [21]. Otros trabajos han evidenciado que los sistemas de asistencia académica basados en IA pueden reducir la procrastinación académica al ofrecer micro-recordatorios contextuales y sugerencias de priorización derivadas del historial de desempeño del usuario [24]. A su vez, investigaciones destacan que los asistentes inteligentes aumentan el rendimiento al guiar la organización semanal con mayor precisión que los métodos manuales tradicionales [29]. De manera complementaria, se ha encontrado que los entornos educativos apoyados por agentes conversacionales reducen el estrés académico al anticipar acumulación de tareas y advertir sobre posibles cuellos de productividad [23]. Finalmente, los sistemas interactivos impulsados por lenguaje natural facilitan la toma de decisiones autónoma, permitiendo a los estudiantes gestionar su tiempo de forma más eficiente mediante recomendaciones personalizadas y adaptativas [27].

La capacidad de la plataforma para mejorar la puntualidad en la finalización de tareas tiene un impacto directo en la formación universitaria y en el desarrollo profesional de los estudiantes. En primer lugar, reduce los periodos de acumulación de actividades, evitando sobrecargas que suelen generar estrés, baja calidad en las entregas y disminución del rendimiento. Asimismo, al promover hábitos de disciplina y constancia, los estudiantes adquieren competencias transversales esenciales en la ingeniería de software, como la gestión del tiempo, el cumplimiento iterativo y el trabajo basado en objetivos, coherentes con la metodología SCRUM. Desde una perspectiva institucional, este tipo de sistemas contribuye a disminuir los niveles de retraso académico y abandono de cursos, favoreciendo trayectorias educativas más estables. En un contexto más amplio, la adopción de plataformas inteligentes consolida el avance hacia modelos de *Smart Campus*, donde la tecnología educativa no solo organiza la información, sino que actúa como un agente activo que guía, anticipa y optimiza el desempeño académico sin incrementar la carga administrativa para la universidad.

Para el Indicador I_4 (Promedio de notas finales por ciclo)

El análisis del Promedio de Notas Finales por Ciclo (I_4) confirmó la normalidad de los datos para ambos grupos ($p_{GC}=0.19$;

$p_{GE}=0.22$), justificando el uso de métodos paramétricos. El Grupo Experimental (GE), que empleó la Plataforma Web Inteligente basada en LLMs, obtuvo una media significativamente mayor de **15.8 puntos**, superando los **12.6 puntos** registrados por el Grupo de Control (GC). Este aumento refleja una mejora relevante en el desempeño académico general. Asimismo, la menor desviación estándar del GE (0.77) frente al GC (0.93) indica que las mejoras no solo fueron superiores en promedio, sino también más consistentes entre los estudiantes. Esto evidencia que el uso de la plataforma, con sus módulos de planificación inteligente, seguimiento continuo del progreso y retroalimentación personalizada, contribuyó a un aprendizaje más estable, sostenido y alineado con los objetivos curriculares del ciclo académico.

El indicador de rendimiento académico se ve impactado de manera directa por las capacidades de organización, guía y apoyo continuo que ofrecen los modelos de Lenguaje Extenso (LLMs). Estudios recientes han demostrado que los sistemas basados en LLMs pueden mejorar el desempeño estudiantil al proporcionar explicaciones adaptadas al nivel cognitivo del usuario y descomponer conceptos complejos en unidades comprensibles, incrementando la retención de conocimiento hasta en un 28% [12]. De igual forma, se ha evidenciado que los asistentes inteligentes generan materiales de estudio coherentes con el contenido oficial del curso, reduciendo la desorientación académica y potenciando la comprensión profunda [15]. Investigaciones también señalan que los sistemas conversacionales educativos pueden aumentar el rendimiento en evaluaciones mediante tutorías personalizadas que ajustan la dificultad de los ejercicios según el perfil del estudiante [19]. Otros trabajos destacan que el uso de plataformas de apoyo académico automatizado reduce la procrastinación y la carga cognitiva, permitiendo un mayor enfoque en actividades de alta relevancia para el aprendizaje [24]. Finalmente, se ha demostrado que los sistemas basados en IA facilitan la autoevaluación constante mediante retroalimentación en tiempo real, mejorando la exactitud con la que los estudiantes identifican sus brechas de conocimiento [17].

El incremento en el rendimiento académico tiene implicancias directas tanto en la formación profesional como en el bienestar del estudiante. Por un lado, un aumento sostenido en las notas finales contribuye a cerrar brechas de aprendizaje y reduce el riesgo de desaprobación, lo que fortalece la continuidad académica y disminuye la deserción universitaria. Por otro lado, la entrega continua de retroalimentación personalizada y la organización sistemática del estudio reducen la ansiedad asociada a los picos de evaluación, fomentando un entorno educativo más saludable y equilibrado. Desde una perspectiva institucional, estos resultados evidencian el potencial de la plataforma para integrarse como una herramienta estratégica en el ecosistema de aprendizaje digital e impulsando modelos de *Smart Campus*, donde el progreso iterativo, la autoorganización y la mejora continua son pilares fundamentales.

Para el Indicador I_5 (Nivel de satisfacción del estudiante)

El análisis del Nivel de Satisfacción del Estudiante (I_5) confirmó la normalidad de los datos en ambos grupos ($p_{GC}=0.148$; $p_{GE}=0.327$), permitiendo el uso de pruebas paramétricas. El Grupo Experimental (GE), que utilizó la Plataforma Web Inteligente basada en LLMs, obtuvo una media de satisfacción de 4.53 puntos en la escala de Likert, superando significativamente los 3.41 puntos registrados por el Grupo de Control (GC). Esta diferencia refleja que la experiencia académica percibida por los estudiantes mejoró de manera

notable con el uso del sistema inteligente. Asimismo, la menor desviación estándar del GE (0.38) frente al GC (0.72) evidencia que el nivel de satisfacción fue no solo más alto, sino también más homogéneo entre los usuarios, lo cual indica una percepción de servicio más consistente y estable. Este resultado sugiere que los módulos de acompañamiento personalizado, recordatorios inteligentes y optimización de carga académica ofrecidos por la plataforma contribuyeron a una experiencia educativa más cómoda, clara y motivadora.

El indicador de satisfacción estudiantil está estrechamente relacionado con las capacidades de personalización, interacción significativa y soporte continuo que proporcionan los modelos de Lenguaje Extenso (LLMs). Investigaciones recientes han demostrado que los asistentes educativos impulsados por IA incrementan la satisfacción al ofrecer apoyo inmediato y retroalimentación conversacional adaptada al estilo cognitivo del usuario, reduciendo la frustración en momentos críticos del aprendizaje [13]. Otros estudios muestran que la presencia constante de un tutor virtual disminuye la sensación de aislamiento académico, especialmente en modalidades híbridas o intensivas, mejorando la percepción de acompañamiento y soporte emocional [18]. Asimismo, la literatura confirma que las plataformas educativas integradas con IA generan experiencias más intuitivas, simplificando la gestión de tareas y permitiendo al estudiante sentir mayor control sobre su avance académico [22]. Además, se ha evidenciado que los sistemas de recomendación elevan la satisfacción al sugerir rutas de aprendizaje personalizadas que incrementan la sensación de progreso y autoeficacia [25]. Finalmente, los entornos educativos inteligentes mejoran la satisfacción global al reducir la fricción cognitiva y aumentar la claridad en la toma de decisiones académicas, especialmente cuando los estudiantes enfrentan múltiples obligaciones y cargas curriculares simultáneas [30].

El aumento en la satisfacción estudiantil tiene implicancias directas tanto en el rendimiento académico como en la permanencia universitaria. Una mayor satisfacción se asocia con niveles superiores de motivación intrínseca, persistencia ante tareas complejas y mayor compromiso con el proceso formativo. Esto contribuye a disminuir el riesgo de abandono, fortalecer la autoconfianza y mejorar la percepción de logro personal. A nivel institucional, estos resultados respaldan el potencial de la plataforma para integrarse como un componente clave de un ecosistema educativo inteligente, donde la experiencia del estudiante es tratada como un factor estratégico para garantizar la continuidad, la retención y el éxito académico.

B. Con Estadística Inferencial: Prueba de Hipótesis

En esa fase se realizaron pruebas de hipótesis para evaluar el impacto del sistema en los 5 indicadores definidos. La Tabla 6 muestra los resultados de los contrastes paramétricos aplicados a los indicadores I1 a I5.

Tabla 5. Contrastación de Hipótesis para los indicadores paramétricos

| Sample | N | H ₀ | t-value | p-value |
|--------------------------------|----|--------------------|---------|---------|
| I ₁ : Posttest (Gc) | 30 | $\mu_1 \geq \mu_2$ | -19.4 | 0.000 |
| I ₁ : Posttest (Ge) | | | | |
| I ₂ : Posttest (Gc) | 30 | $\mu_1 \leq \mu_2$ | 22.9 | 0.000 |
| I ₂ : Posttest (Ge) | | | | |
| I ₃ : Posttest (Gc) | 30 | $\mu_1 \geq \mu_2$ | -35.2 | 0.000 |
| I ₃ : Posttest (Ge) | | | | |

| | | | | |
|--------------------------------|----|--------------------|-------|-------|
| I ₄ : Posttest (Gc) | 30 | $\mu_1 \geq \mu_2$ | -11.1 | 0.000 |
| I ₄ : Posttest (Ge) | | | | |
| I ₅ : Posttest (Gc) | 30 | $\mu_1 \geq \mu_2$ | -11.2 | 0.000 |
| I ₅ : Posttest (Ge) | | | | |

Para el Indicador I1 (Postest), con n = 30, la hipótesis nula ($\mu_1 \geq \mu_2$) fue rechazada al obtener un t-value de -19.4 y un p-value de 0.000. Esto refleja un efecto altamente significativo de la intervención. El contraste confirma que la diferencia entre el Grupo de Control (GC) y el Grupo Experimental (GE) en el tiempo de estudio promedio no es atribuible al azar, validando que la Plataforma Web Inteligente con LLMs, implementada mediante SCRUM, optimiza la gestión de las actividades académicas de los estudiantes de Ingeniería de Software de la UNMSM.

El significativo rechazo de la hipótesis nula para el Indicador I1 se respalda en la literatura que vincula el uso de plataformas inteligentes con la mejora de la productividad académica y la reducción de retrasos en la entrega de tareas. Estudios previos han demostrado que los sistemas con LLMs permiten planificar, organizar y monitorear las actividades académicas de manera más eficiente, aumentando la probabilidad de cumplimiento de plazos y mejorando el rendimiento estudiantil [18]. De manera similar, Natesan y colaboradores reportaron que la guía automatizada en entornos educativos reduce los retrasos en la entrega de trabajos y tareas críticas (P = 0.04), lo que se traduce directamente en una mejor gestión del tiempo y mayor eficiencia en los procesos de aprendizaje [19]. Por lo tanto, estos hallazgos validan la hipótesis de que la Plataforma Web Inteligente con LLMs y SCRUM incrementa significativamente la productividad académica y reduce la variabilidad en la ejecución de actividades.

La magnitud estadística evidencia que la plataforma no solo optimiza los procesos académicos actuales, sino que también permite identificar una “demanda latente” que permanecía oculta debido a las limitaciones de los métodos tradicionales. Esta eficiencia implica que la institución educativa puede evitar el “costo de oportunidad” asociado a tareas incompletas o retrasadas, asegurando la correcta gestión de todas las actividades académicas. Su implementación resulta fundamental en períodos de alta carga académica, donde los métodos convencionales podrían generar retrasos o sobrecarga. De esta manera, la plataforma garantiza una gestión continua y confiable de las actividades estudiantiles, optimizando recursos y mejorando la experiencia general de aprendizaje.

Para el Indicador I2 (Postest), con n = 30, la hipótesis nula ($\mu_1 \leq \mu_2$) fue rechazada al obtener un t-value de 22.9 y un p-value de 0.000. Esto refleja un efecto altamente significativo de la intervención. El contraste confirma que la diferencia entre el Grupo de Control (GC) y el Grupo Experimental (GE) en el tiempo promedio para completar una tarea desde su asignación no es atribuible al azar, validando que la Plataforma Web Inteligente con LLMs, implementada mediante SCRUM, impacta positivamente en la eficiencia académica y en la gestión del tiempo de los estudiantes de Ingeniería de Software de la UNMSM.

La significancia obtenida en el Indicador I2 se respalda en investigaciones que muestran cómo las plataformas inteligentes pueden mejorar la planificación y seguimiento de actividades académicas, reduciendo los retrasos y promoviendo el cumplimiento de los plazos. Estudios previos han demostrado que los sistemas con LLMs permiten anticipar la carga de trabajo, organizar tareas y brindar recordatorios estratégicos, lo

que incrementa la productividad y disminuye la variabilidad en la ejecución [22]. Asimismo, la implementación de metodologías ágiles como SCRUM refuerza esta capacidad al permitir iteraciones cortas, seguimiento continuo y retroalimentación constante, optimizando la ejecución de tareas [21]. Finalmente, la personalización y monitoreo en tiempo real permiten a los estudiantes priorizar actividades críticas, reduciendo la procrastinación y mejorando el rendimiento académico general [24].

El rechazo de la hipótesis nula en el Indicador I2 valida que la mejora en la eficiencia para completar tareas es una consecuencia directa de la planificación proactiva y la estructura de seguimiento que ofrece la plataforma. La gestión del tiempo deja de ser reactiva y se convierte en estratégica, permitiendo que los estudiantes identifiquen y aborden primero las tareas más críticas. Al reducir la incertidumbre y garantizar la ejecución oportuna, la plataforma transforma la productividad académica, fortaleciendo la responsabilidad, la autonomía y la capacidad de organización de los estudiantes.

Para el Indicador I3 (Postest), con $n = 30$, la hipótesis nula ($\mu_1 \geq \mu_2$) fue rechazada al obtener un t-value de -35.2 y un p-value de 0.000. Esto refleja un efecto altamente significativo de la intervención. El contraste confirma que la diferencia entre el Grupo de Control (GC) y el Grupo Experimental (GE) en la tasa de finalización de tareas a tiempo no es atribuible al azar, validando que la Plataforma Web Inteligente con LLMs, implementada mediante SCRUM, influye de manera significativa en la gestión puntual de actividades académicas de los estudiantes de Ingeniería de Software de la UNMSM.

El fuerte rechazo de la hipótesis nula para el Indicador I3 se alinea con la evidencia que vincula las plataformas inteligentes con mejoras en la puntualidad y cumplimiento de tareas. Investigaciones previas han demostrado que los sistemas con LLMs permiten monitorear el progreso de las actividades en tiempo real, enviar recordatorios estratégicos y priorizar tareas críticas, aumentando significativamente la probabilidad de que los estudiantes completen sus tareas dentro de los plazos establecidos [29]. De manera similar, la implementación de SCRUM refuerza esta capacidad al organizar el trabajo en iteraciones cortas y generar revisiones periódicas, fomentando la responsabilidad y la autonomía de los estudiantes [27]. Además, la personalización del seguimiento de tareas y la retroalimentación constante permiten identificar obstáculos o retrasos antes de que afecten los resultados académicos, optimizando el rendimiento general [24].

La significancia estadística evidencia que la plataforma no solo mejora la puntualidad en la entrega de tareas, sino que también establece un control proactivo sobre la productividad académica. Al anticipar los puntos críticos y garantizar la finalización oportuna de las actividades, la plataforma transforma la gestión del tiempo y refuerza la disciplina académica. Este enfoque asegura que los estudiantes desarrollen hábitos consistentes de cumplimiento y que los recursos educativos se utilicen de manera eficiente, potenciando el desempeño general y la calidad de la experiencia académica.

Para el Indicador I4 (Postest), con $n = 30$, la hipótesis nula ($\mu_1 \geq \mu_2$) fue rechazada al obtener un t-value de -11.1 y un p-value de 0.000. Esto refleja un efecto altamente significativo de la intervención. El contraste confirma que la diferencia entre el Grupo de Control (GC) y el Grupo Experimental (GE) en el promedio de notas finales por ciclo no es atribuible al azar, validando que la Plataforma Web Inteligente con LLMs, implementada mediante SCRUM, impacta de manera positiva

en el rendimiento académico de los estudiantes de Ingeniería de Software de la UNMSM.

El resultado altamente significativo para el Indicador I4 confirma que la intervención tuvo un efecto directo en el **promedio de notas finales por ciclo**, evidenciando una mejora sustancial en el rendimiento académico de los estudiantes. Estudios previos han mostrado que los sistemas con LLMs permiten organizar los contenidos, generar retroalimentación personalizada y priorizar los temas críticos, lo que facilita la comprensión y contribuye a un mayor aprovechamiento del tiempo de estudio [2]. Asimismo, la aplicación de metodologías ágiles como SCRUM favorece la planificación de ciclos de trabajo cortos, la revisión periódica de avances y la entrega oportuna de actividades, factores que inciden directamente en la elevación de las calificaciones finales [17]. De manera complementaria, la personalización del seguimiento permite identificar tempranamente dificultades individuales, ofreciendo estrategias específicas para superar los obstáculos de aprendizaje y mejorar el desempeño evaluativo [14].

La significancia estadística evidencia que el sistema no solo optimiza el flujo de estudio, sino que también garantiza un impacto concreto en el promedio de notas, asegurando que los estudiantes logren un rendimiento académico más consistente y elevado. Al anticipar las dificultades y orientar las actividades estratégicamente, la plataforma permite maximizar el desempeño en cada ciclo académico, asegurando que las evaluaciones reflejen de manera más precisa el nivel de aprendizaje adquirido.

Para el Indicador I5 (Postest), con $n = 30$, la hipótesis nula ($\mu_1 \geq \mu_2$) fue rechazada al obtener un t-value de -11.2 y un p-value de 0.000. Esto refleja un efecto altamente significativo de la intervención. El contraste confirma que la diferencia entre el Grupo de Control (GC) y el Grupo Experimental (GE) en el nivel de satisfacción de los estudiantes no es atribuible al azar, validando que la Plataforma Web Inteligente con LLMs, implementada mediante SCRUM, impacta de manera positiva en la percepción de los estudiantes sobre la gestión de sus actividades académicas.

El resultado altamente significativo para el Indicador I5 se alinea con la evidencia que vincula las plataformas inteligentes con mejoras en la experiencia y satisfacción del usuario. Estudios previos han demostrado que los sistemas con LLMs facilitan la personalización del aprendizaje, el seguimiento de tareas y la retroalimentación en tiempo real, lo que incrementa la percepción de control y confianza en el proceso académico [2]. Asimismo, la implementación de metodologías ágiles como SCRUM permite iteraciones cortas, comunicación constante y visibilidad de avances, factores que contribuyen directamente a la satisfacción de los estudiantes [17]. La capacidad de la plataforma para anticipar necesidades, priorizar actividades y ofrecer sugerencias personalizadas refuerza la sensación de acompañamiento y apoyo, mejorando la experiencia educativa [14].

La significancia estadística evidencia que la plataforma no solo organiza y optimiza las actividades académicas, sino que también incrementa el nivel de satisfacción de los estudiantes, asegurando que su percepción sobre la gestión del tiempo, la carga de trabajo y el aprendizaje sea positiva. Al proporcionar herramientas de seguimiento, recordatorios estratégicos y retroalimentación constante, la plataforma transforma la experiencia académica de reactiva a proactiva, fomentando un mayor compromiso, motivación y bienestar académico.

VI. CONCLUSIONES Y TRABAJO FUTURO

De manera integral, la investigación demuestra que la adopción de la **Plataforma Web Inteligente con LLMs, implementada mediante SCRUM**, ha generado un cambio significativo en la gestión de las actividades académicas de los estudiantes de Ingeniería de Software de la UNMSM, transitando de un modelo tradicional, reactivo y disperso, a uno proactivo, organizado y centrado en la eficiencia académica. La significancia obtenida en el Indicador I1 valida que la capacidad de la plataforma para optimizar el flujo de estudio se traduce en una mejora crítica en la planificación diaria. La reducción efectiva del tiempo promedio de estudio y la organización de las tareas permite a los estudiantes desbloquear su productividad latente, garantizando un aprovechamiento más eficiente de las horas disponibles y una distribución equilibrada de las cargas académicas. Esta eficiencia es vital, ya que la gestión del tiempo impacta directamente en el desempeño y la consolidación de hábitos de estudio sostenibles. En cuanto al Indicador I2, la plataforma demuestra un impacto positivo en la **finalización de tareas a tiempo**. La planificación proactiva, los recordatorios estratégicos y el seguimiento personalizado de cada actividad permiten a los estudiantes cumplir con los plazos establecidos, reduciendo la procrastinación y aumentando la responsabilidad individual. Al anticipar posibles retrasos y ofrecer herramientas de gestión claras, la plataforma transforma la organización del trabajo de ser reactiva a ser estratégica, promoviendo una mayor eficiencia en la ejecución de actividades académicas. El Indicador I3 evidencia que la plataforma actúa como un mecanismo de control integral sobre la **tasa de finalización de tareas**, asegurando que los estudiantes mantengan un desempeño constante y confiable. La combinación de metodologías ágiles como SCRUM con los LLMs permite priorizar tareas críticas, monitorear progresos en tiempo real y brindar retroalimentación inmediata, optimizando la productividad y reduciendo la variabilidad en el cumplimiento de responsabilidades académicas. Esto genera un entorno académico más predecible y confiable, en el que los estudiantes pueden gestionar su carga de trabajo de manera más efectiva. El resultado para el Indicador I4 confirma que la plataforma impacta positivamente en el **promedio de notas finales por ciclo**. La integración de seguimiento personalizado, planificación de actividades y priorización de contenidos permite a los estudiantes maximizar el aprendizaje en cada ciclo académico. Al identificar dificultades individuales y proporcionar estrategias de mejora oportunas, la plataforma contribuye a elevar el desempeño académico general, optimizando los recursos de estudio y garantizando que las evaluaciones reflejen con mayor fidelidad los conocimientos adquiridos. Finalmente, el Indicador I5 demuestra que la plataforma mejora significativamente el **nivel de satisfacción de los estudiantes**. La percepción positiva se relaciona con la organización clara de las actividades, la retroalimentación constante y la personalización de la experiencia educativa. Al facilitar el seguimiento, anticipar necesidades y ofrecer apoyo estratégico, la plataforma transforma la experiencia académica de los estudiantes, incrementando su motivación, compromiso y confianza en la gestión de su aprendizaje. En conjunto, los resultados muestran que la **Plataforma Web Inteligente con LLMs y SCRUM** no solo mejora la eficiencia operativa de los estudiantes, sino que también incrementa la calidad del aprendizaje, la puntualidad en la ejecución de tareas y la satisfacción general. Su implementación permite que los estudiantes optimicen su tiempo, prioricen actividades críticas y gestionen de manera efectiva su carga académica, consolidando un entorno de estudio más productivo, organizado y motivador. Para trabajos futuros, se recomienda explorar la integración de herramientas de análisis de datos de comportamiento de los estudiantes, funcionalidades de

gamificación para aumentar el compromiso, y módulos de asistencia personalizada que adapten dinámicamente las sugerencias y recordatorios según los patrones de estudio individuales. Estas mejoras podrían potenciar aún más la eficacia de la plataforma y ampliar su impacto en la productividad académica de manera sostenible.

La principal limitación técnica de la plataforma radica en la **falta de integración completa con todos los sistemas académicos y recursos digitales disponibles para los estudiantes**, lo que restringe la capacidad del sistema para consolidar información dispersa sobre tareas, calificaciones y horarios. Esta limitación puede afectar la precisión de las recomendaciones personalizadas y el seguimiento integral de la productividad académica. Se recomienda que la plataforma se integre con estándares de interoperabilidad de entornos educativos y bases de datos institucionales, permitiendo un **Data Lake académico centralizado** que unifique información de distintas fuentes, como sistemas de matrícula, plataformas de aprendizaje y repositorios de contenido. Además, resulta fundamental incluir en cada recomendación o recordatorio generado por la plataforma una **trazabilidad clara del origen de la información** (por ejemplo, la asignatura, curso o docente responsable), garantizando transparencia, confiabilidad y facilidad de verificación por parte de los estudiantes y personal académico.

AGRADECIMIENTOS

REFERENCIAS

1. Acuña, C. A. A., Sabili, M. A., & Friginal, F. F. S. (2024). MARA: A mobile-based academic reminder application. *International Journal of Computing Sciences Research*, 8, 2734–2748. <https://stepacademic.net/ijcsr/article/view/493>
2. Bashab, A., Osman, A., Tarigo Hashem, I. A., & Aggarwal, K. (2022). Optimization techniques in university timetabling problem: Constraints, methodologies, benchmarks, and open issues. *Computers, Materials & Continua*, 74(3), 6461–6484. <https://doi.org/10.32604/cmc.2023.034051>
3. Bhattacharjee, A., Zeng, Y., Xu, S. Y., Kulzhabayeva, D., Ma, M., Kornfield, R., Ahmed, S. I., Mariakakis, A., Czerwinski, M. P., Kuzminykh, A., Liut, M., & Williams, J. J. (2024). Understanding the role of large language models in personalizing and scaffolding strategies to combat academic procrastination. *NPJ Science of Learning*, 9(1). <https://pmc.ncbi.nlm.nih.gov/articles/PMC11166253/>
4. Diallo, F. P., & Tudose, C. (2024). Optimizing the scheduling of teaching activities in a faculty. *Applied Sciences*, 14(20), 9554. <https://doi.org/10.3390/app14209554>
5. Doğan, A. (2025). An experimental framework for student course recommendation using large language models. *Innovative Artificial Intelligence*, 1(1), 21–28. <https://dergipark.org.tr/en/pub/innai/issue/92049/1675106>
6. Doğan, A. (2025). An experimental framework for student course recommendation using large language models. *Innovative Artificial Intelligence*, 1(1), 21–28. <https://dergipark.org.tr/en/pub/innai/issue/92049/1675106>
7. Elmoghazy, S. S., Shouman, M. A., Elminir, H. K., & Selim, G. E. I. (2025). Comparative analysis of methodologies and approaches in recommender systems utilizing large language models. *Artificial Intelligence Review*, 58, Article 207. <https://doi.org/10.1007/s10462-025-11189-8>
8. Fernex, A., Filippi, L., Maghraoui, M., & Rachdi, M. (2025). Towards intelligent time management applications for students: A technical framework for data collection, modeling, and personalized feedback. *Journal of Artificial Intelligence & Robotics*, 2(2), 1024. <https://joaiar.org/articles/AIR-1024.html>
9. Filippi, S., & Motyl, B. (2024). Large language models (LLMs) in engineering education: A systematic review and suggestions for practical adoption. *Information*, 15(6), 345. <https://doi.org/10.3390/info15060345>
10. Ghaffar, A., Ud Din, I., Tariq, A., & Zafar, M. H. (2025). Hybridization and artificial intelligence in optimizing university examination timetabling problem: A systematic review. *Review of Education*, 13(2), Article e70071. <https://doi.org/10.1002/rev3.70071>
11. Gu, X., Krish, M., Sohail, S., Thakur, S., Sabrina, F., & Fan, Z. (2025). From integer programming to machine learning: A technical review on solving university timetabling problems. *Computation*, 13(1), 10. <https://doi.org/10.3390/computation13010010>
12. Goslen, A., Kim, Y. J., Rowe, J., & Lester, J. (2024). LLM-based student plan generation for adaptive scaffolding in game-based learning environments. *International Journal of Artificial Intelligence in Education*, 35, 533–558. <https://doi.org/10.1007/s40593-024-00421-1>
- 13.
14. Krishnamurthy, B., & Shiva, S. G. (2025). Large language model-guided SARSA algorithm for dynamic task scheduling in cloud computing. *Mathematics*, 13(6), 926. <https://doi.org/10.3390/math13060926>
15. Li, J., Lyu, Q., Qiu, W., & Khong, A. W. H. (2025). Improving course recommendation systems with explainable AI: LLM-based frameworks and evaluations. *Proceedings of the 18th International Conference on Educational Data Mining (EDM 2025)*. <https://educationaldatamining.org/EDM2025/proceedings/2025.EDM.long-papers.221/index.html>
16. Liu, Q., Hu, A., Gladman, T., & Gallagher, S. (2025). Eight months into reality: A scoping review of the application of ChatGPT in higher education teaching and learning. *Innovative Higher Education*, 50, 1677–1700. <https://doi.org/10.1007/s10755-025-09790-4>
17. Lichtenberg, J. M., Buchholz, A., & Schwöbel, P. (2024). Large language models as recommender systems: A study of popularity bias. *Amazon Science Publications*. <https://www.amazon.science/publications/large-language-models-as-recommender-systems-a-study-of-popularity-bias>
18. Mannekote, A., Davies, A., Pinto, J. D., Zhang, S., Olds, D., Schroeder, N. L., Lehman, B., Zapata-Rivera, D., & Zhai, C. (2024). Large language models for whole-learner support: Opportunities and challenges. *NPJ Science of Learning*, 9(1), Article 40. <https://pmc.ncbi.nlm.nih.gov/articles/PMC11518847/>
19. Mohamad Zukriyani, F. A., & Azizan, N. (2023). Student academic planner system: A review. *Malaysian Journal of Science, Health & Technology (MJOSH&T)*, 9(1), 1–10. <https://doi.org/10.33102/mjosht.v9i1.326>
20. Mumcu, B. B., & Çebi, A. (2025). You have a notification: The role of push notifications in shaping students' engagement, self-regulation, and academic procrastination. *International Journal of Educational Technology in Higher Education*, 22(36). <https://doi.org/10.1186/s41239-025-00537-x>
21. Munson, J., Cuzzze, T., Nesar, S., & Zosso, D. (2025). A review of large language models and the recommendation task. *Discover Artificial Intelligence*, 5, Article 203. <https://doi.org/10.1007/s44163-025-00334-5>
22. Nobbe, L., Breitwieser, J., Biedermann, D., & Brod, G. (2024). Smartphone-based study reminders can be a double-edged sword. *NPJ Science of Learning*, 9(1), 40. <https://doi.org/10.1038/s41539-024-00253-7>
23. Nobbe, L., Breitwieser, J., Biedermann, D., & Brod, G. (2024). Smartphone-based study reminders can be a

double-edged sword. NPJ Science of Learning, 9, 40. <https://doi.org/10.1038/s41539-024-00253-7>

24. Pelánek, R., Effenberger, T., & Jarušek, P. (2024). Personalized recommendations for learning activities in online environments: A modular rule-based approach. User Modeling and User-Adapted Interaction, 34, 1399–1430. <https://doi.org/10.1007/s11257-024-09396-z>
25. Powell, C., & Riccardi, A. (2025). Generating textual explanations for scheduling systems leveraging the reasoning capabilities of large language models. Journal of Intelligent Information Systems, 63, 1287–1337. <https://doi.org/10.1007/s10844-025-00940-w>
26. Powell, C., & Riccardi, A. (2025). Generating textual explanations for scheduling systems leveraging the reasoning capabilities of large language models. Journal of Intelligent Information Systems, 63, 1287–1337. <https://doi.org/10.1007/s10844-025-00940-w>
27. Trichopoulos, G., Konstantakis, M., Alexandridis, G., & Caridakis, G. (2023). Large language models as recommendation systems in museums. Electronics, 12(18), 3829. <https://doi.org/10.3390/electronics12183829>
28. Ventura Roque Hernández, R., Herrera Izaguirre, J. A., López Mendoza, A., & Salinas Escandón, J. M. (2023). A practical approach to the agile development of mobile apps in the classroom. Innovación Educativa, 17(73), 97–112. <https://www.scielo.org.mx/pdf/ie/v17n73/1665-2673-ie-17-73-00097.pdf>
29. Wang, S., Sporrel, K., van Hoof, H., Simons, M., de Boer, R. D. D., Ettema, D., Nibbeling, N., Deutekom, M., & Kröse, B. (2021). Reinforcement learning to send reminders at right moments in smartphone exercise application: A feasibility study. International Journal of Environmental Research and Public Health, 18(11), 6059. <https://doi.org/10.3390/ijerph18116059>
30. Wang, S., Wang, F., Zhu, Z., Wang, J., Tran, T., & Du, Z. (2024). Artificial intelligence in education: A systematic literature review. Expert Systems with Applications, 242, 124167. <https://doi.org/10.1016/j.eswa.2024.124167>
31. Zhao, W., Harb, H., Muntaser, M., Bernacki, P., Robison, J., & Perri, J. (2024). Design and implementation of a time management self-help mobile app for college students. IEEE Xplore Digital Library. <https://ieeexplore.ieee.org/document/10402177>
32. Zuo, M., Wang, K., Tang, P., Xiao, M., Zhou, X., & Luo, H. (2025). Predicting academic performance from future-oriented daily time management behavior: A LASSO-based study of first-year college students. Behavioral Sciences, 15(9), 1242. <https://doi.org/10.3390/bs15091242>

ANEXOS

Anexo 1:

Anexo 2:

Anexo 3:

Front-end en español